

Machine Learning non supervisé pour le clustering des galaxies

Master Mathématiques Appliquées à l'Ingénierie,
l'Industrie et l'Innovation MApI3

Étudiante :

Sarah Yahiaoui

Sous la supervision de :

Jihane Moulta

Researcher CNAP , IRAP-CNRS

Stage réalisé du 27 avril au 28 août 2026 à

L'Observatoire Midi Pyrénées

16 avenue Edouard Belin, Toulouse

Année : 2025-2026

Résumé

Les galaxies présentent une grande diversité de propriétés physiques et spectrales. Les observations mettent cependant en évidence une séparation globale entre deux grandes familles, les galaxies bleues et les galaxies rouges. L'étude de ces deux familles nécessite l'exploitation de grands relevés astronomiques ainsi que l'utilisation de méthodes statistiques adaptées.

Dans ce contexte, les méthodes de Machine Learning non supervisé constituent des outils efficaces pour analyser des données multidimensionnelles et identifier automatiquement des structures dans les populations galactiques. Ce travail porte sur la classification de galaxies issues du survey Galaxy And Mass Assembly (GAMA), en exploitant leurs données spectroscopiques.

L'algorithme Fisher-EM, basé sur les modèles de mélanges gaussiens discriminants, est utilisé pour réaliser le clustering des galaxies. Cette méthode, adaptée aux données de grande dimension, permet de rechercher un espace latent dans lequel les différentes populations sont mieux séparées. L'étude est réalisée sur un échantillon de spectres issus du survey AAOmega 3.1.2 afin d'explorer l'apport des propriétés spectrales dans la classification des galaxies.

Les résultats obtenus montrent le potentiel de cette approche pour caractériser automatiquement les populations galactiques et ouvrent des perspectives pour une meilleure compréhension de leur formation et de leur évolution.

Remerciements

Je tiens particulièrement à remercier mon encadrante, **Jihane Moulta**, pour l'opportunité qu'elle m'a offerte de réaliser ce stage, qui m'a permis de développer mes compétences scientifiques et techniques. Je lui suis également reconnaissante pour la qualité de son accompagnement, sa disponibilité, sa patience et ses précieux conseils tout au long de ce travail.

Je souhaite également remercier **Étienne Gondet**, responsable du Service Formation et Appui Numérique de l'OMP, pour son accompagnement tout au long de mon stage ainsi que pour l'organisation des ateliers numériques et des journées thématiques. Ces événements m'ont permis d'échanger avec différentes personnes du domaine scientifique et d'enrichir mon expérience.

Table des matières

1	Présentation de L'Observatoire Midi Pyrénées	3
1.0.1	Le réseau ENV'IA	3
1.0.2	L'Institut de Recherche en Astrophysique et Planétologie	3
2	Introduction et Contexte astrophysique	4
2.1	Introduction générale	4
2.2	Contexte astrophysique	4
2.3	La classification morphologique de Hubble	5
3	GAMA Survey et données	7
3.0.1	L'échantillon de galaxies	7
3.0.2	Extraction et nettoyage des données	8
3.0.3	Traitement des unités et standardisation	9
3.1	Spectres de galaxie	10
3.1.1	Spectres SDSS	10
3.1.2	Survey AAOmega	11
3.1.3	Prétraitement des spectres	12
4	Algorithme de Machine Learning non supervisé	16
4.1	Algorithme Fisher-EM	16
4.1.1	Modèle de mélanges gaussiens	17
4.1.2	Implémentation de l'algorithme Fisher-EM sous R	21
4.1.3	Critère de convergence et sélection du modèle	22
4.1.4	Difficultés rencontrées lors de l'implémentation	22
5	Résultats du clustering	23
5.1	Les spectres AAOmega	23
5.2	Les spectres AAOmega sur une grille de rééchantillonnage des spectres SDSS	26
5.3	Les spectres AAOmega avec les spectres SDSS	27
6	Conclusion et perspectives	28
6.1	Perspectives	28
	Bibliographie	29
A	Résultats du clustering pour certains K	30
A.1	Les spectres AAOmega	30
A.2	Les spectres AAOmega rééchantillonnés sur la grille SDSS	32
A.3	Les spectres AAOmega et SDSS	35

Présentation de L'Observatoire Midi Pyrénées

L'Observatoire Midi-Pyrénées (OMP) est un Observatoire des Sciences de l'Univers (OSU) qui fédère plusieurs laboratoires de recherche de la région Occitanie autour de l'étude de l'Univers, de la planète et de l'environnement. Ses activités s'articulent autour de plusieurs missions principales : la recherche scientifique, l'observation, l'enseignement, la diffusion de la culture scientifique et la coopération internationale.

L'OMP regroupe des équipes travaillant sur des thématiques variées. Il constitue également une structure de coordination entre plusieurs laboratoires spécialisés dans les sciences de l'Univers. [6] : **IRAP** (Planétologie et astrophysique), **LAERO** (Aérologie), **CESBIO** (Etudes spatiales et Biosphère), **LEGOS** (Océanographie) et **GET** (Géosciences).

1.0.1 Le réseau ENV'IA

Le réseau ENV'IA est une initiative dédiée au développement de l'intelligence artificielle appliquée aux Sciences de l'Environnement, de l'Écologie, de l'Espace et de l'Univers (S3EU). Il favorise les collaborations entre les chercheurs des domaines scientifiques liés à l'environnement et les spécialistes de l'intelligence artificielle. Dans le cadre de cette mission ENV'IA finance des projets et des stages de recherche. Ce stage réalisé à l'IRAP, bénéficie de ce financement.

1.0.2 L'Institut de Recherche en Astrophysique et Planétologie

L'Institut de Recherche en Astrophysique et Planétologie (IRAP) est une unité mixte de recherche (UMR 5277) associée au Centre National de la Recherche Scientifique (CNRS), à l'Université de Toulouse et au Centre National d'Études Spatiales (CNES). Membre de l'Observatoire Midi-Pyrénées [6], l'IRAP mène des recherches sur l'étude et la compréhension de l'Univers et de ses constituants, notamment les étoiles, les systèmes planétaires, le milieu interstellaire, les galaxies, les objets compacts ainsi que les premières phases de l'évolution de l'Univers.

Ces recherches reposent sur l'observation astronomique, la modélisation théorique, l'analyse de données et le développement d'instruments destinés aux observations au sol et spatiales. [5]

Dans le cadre de ce stage, réalisé au sein de l'IRAP, l'objectif est d'utiliser des méthodes de Machine Learning afin d'analyser des données astronomiques et d'étudier la diversité des populations de galaxies à partir de leurs propriétés spectroscopiques.

Introduction et Contexte astrophysique

2.1 Introduction générale

L'astronomie moderne s'appuie sur de vastes relevés observationnels qui produisent une quantité considérable de données. Les progrès des instruments d'observation permettent aujourd'hui d'acquérir des informations détaillées sur des millions de galaxies, ouvrant ainsi de nouvelles perspectives pour l'étude de l'Univers.

Face à cette croissance continue des données, leur analyse manuelle devient difficile, voire impossible. Les méthodes de Machine Learning offrent des outils performants pour explorer automatiquement ces grandes bases de données, mettre en évidence des structures sous-jacentes et regrouper des objets présentant des caractéristiques similaires.

Parmi ces objets, les galaxies occupent une place centrale en astrophysique. Leur étude permet de mieux comprendre les mécanismes de formation et d'évolution de l'Univers. En particulier, leurs spectres constituent une source d'information essentielle, car ils renseignent sur leurs propriétés physiques, telles que leur composition chimique, leurs populations stellaires ou encore leur activité de formation d'étoiles.

2.2 Contexte astrophysique

Les galaxies sont des systèmes gravitationnellement liés composés d'étoiles, de gaz, de poussières et de matière noire. Elles présentent une grande diversité de propriétés morphologiques et physiques, témoignant des différents processus qui gouvernent leur évolution au cours du temps.

Le spectre d'une galaxie, obtenu par décomposition de sa lumière en fonction de la longueur d'onde, fournit une signature de ces propriétés. Le continuum reflète principalement les populations stellaires, tandis que les raies d'émission et d'absorption permettent d'étudier la composition chimique, les conditions physiques du milieu interstellaire ainsi que l'activité de formation stellaire.

Les observations mettent en évidence deux grandes populations de galaxies. Les **galaxies bleues** sont généralement riches en gaz et caractérisées par une formation stellaire active. Leur spectre présente un continuum plus bleu ainsi que de fortes raies d'émission. À l'inverse, les **galaxies rouges** sont pauvres en gaz, dominées par des populations stellaires plus âgées et présentent une faible activité de formation d'étoiles. Leur spectre est principalement marqué par un continuum plus rouge et des raies d'absorption plus prononcées.

L'identification automatique de ces différentes populations constitue un enjeu majeur en astrophysique. Les méthodes de clustering permettent d'exploiter efficacement les don-

nées spectroscopiques afin de regrouper les galaxies selon leurs caractéristiques communes et de mieux comprendre les liens entre leurs propriétés physiques et leur évolution.

2.3 La classification morphologique de Hubble

La première classification systématique des galaxies a été proposée par Edwin Hubble en 1926. Elle repose exclusivement sur l'observation de leur morphologie et constitue encore aujourd'hui une référence en astrophysique.

Hubble a organisé les galaxies selon leur apparence visuelle dans un schéma connu sous le nom de diagramme en diapason (Hubble tuning fork) 2.1. Cette classification distingue principalement trois grandes catégories :

- les **galaxies elliptiques (E)**, caractérisées par une forme sphérique ou elliptique et une faible quantité de gaz et de poussières ;
- les **galaxies spirales (S)** et **spirales barrées (SB)**, présentant un disque aplati, des bras spiraux et, pour certaines, une barre centrale ;
- les **galaxies irrégulières (Irr)**, qui ne possèdent pas de structure morphologique bien définie.

Cette classification a constitué une étape majeure dans l'étude des galaxies en permettant leur description selon des critères morphologiques simples. Toutefois, avec l'augmentation considérable du nombre de galaxies observées par les grands relevés astronomiques, une classification visuelle devient difficile à mettre en œuvre à grande échelle. De plus, des galaxies présentant une morphologie similaire peuvent posséder des propriétés physiques ou spectrales très différentes.

Ces limites ont conduit au développement de méthodes automatiques de classification fondées sur l'analyse de données multidimensionnelles, notamment les approches de Machine Learning.




FIGURE 2.1 – Classification morphologique des galaxies proposée par E.Hubble (1926).

Objectif du stage

Après la classification de E.Hubble 2.1, plusieurs autres classifications ont été proposées, principalement fondées sur la morphologie des galaxies. Cependant, la morphologie ne permet pas à elle seule de décrire l'ensemble de leurs propriétés physiques. Les spectres des galaxies apportent des informations complémentaires et permettent notamment d'étudier leur composition et leur évolution.

En effet, un spectre contient des informations sur les différentes composantes physiques d'une galaxie. Le continuum spectral et les raies en absorption sont principalement liés aux populations stellaires et permettent notamment de renseigner sur l'âge des étoiles. Les raies d'émission fournissent des informations sur le gaz présent dans la galaxie, sa composition chimique et les conditions physiques du milieu interstellaire, ainsi que sur les événements de formation stellaire dans les galaxies. Certaines raies d'émission sont également associées à la formation récente d'étoiles. Le spectre permet ainsi de caractériser une galaxie à partir d'un ensemble d'informations physiques plus riche que sa seule morphologie.

L'objectif de mon stage est donc de réaliser une classification non supervisée (*clustering*) des galaxies à partir de leurs spectres. L'idée est de regrouper automatiquement les galaxies présentant des caractéristiques spectrales similaires, sans définir au préalable les classes recherchées. Cette approche peut ainsi permettre de mettre en évidence différentes populations de galaxies et d'étudier leurs propriétés.

Ce travail s'inscrit dans la continuité d'une étude menée précédemment par une autre stagiaire de l'IRAP, au cours de laquelle deux classifications ont été réalisées sur un même échantillon de galaxies défini par Turner et al. (2018)[7]. La première classification a été effectuée à partir des spectres du survey SDSS, tandis que la seconde a été réalisée à partir de cinq paramètres physiques : la masse stellaire, la couleur de la galaxie, l'indice de Sérsic, le rayon effectif et le taux de formation stellaire spécifique (sSFR).

Mon stage consiste à poursuivre cette étude en conservant le même échantillon de galaxies, mais en exploitant les spectres issus du survey AAOmega. Ce nouveau jeu de données permet d'étendre l'étude à un nombre plus important de spectres et de comparer les classifications obtenues à partir des données AAOmega avec celles obtenues à partir des spectres SDSS et des cinq paramètres physiques.

L'objectif est ainsi d'évaluer la capacité de l'algorithme non supervisé Fisher-EM à identifier des groupes de galaxies à partir de leur information spectrale, tout en étudiant les liens entre ces groupes et les propriétés physiques des galaxies.

GAMA Survey et données

Le *Galaxy And Mass Assembly (GAMA)* survey [3] est un programme international d'astronomie visant à étudier les propriétés physiques des galaxies dans l'Univers local. Son objectif principal est d'établir des relations cohérentes entre les propriétés intrinsèques des galaxies, leur environnement, ainsi que leur évolution cosmologique.

Les données issues du survey sont structurées sous forme de tables scientifiques spécialisées (masse stellaire, morphologie, distances cosmologiques, etc.), interconnectées via un identifiant unique (CATAID). Cette organisation permet de constituer un jeu de données homogène regroupant les paramètres physiques associés à chaque galaxie.

Dans le cadre de mon travail, la première étape a consisté à constituer un échantillon de galaxies à analyser à l'aide de méthodes de Machine Learning. Pour cela, je me suis appuyée sur l'étude de Turner et al. (2018) [7], qui utilise les données du survey GAMA afin de réaliser une classification non supervisée des galaxies à partir de leurs propriétés physiques. Les auteurs appliquent une méthode de clustering par *k-means* sur cinq paramètres physiques caractérisant les galaxies : la masse stellaire, la couleur $u - r$, l'indice de Sérsic, le rayon demi-lumière et le taux de formation stellaire spécifique (sSFR).

Ce même échantillon a ensuite été repris dans le travail réalisé précédemment par une autre stagiaire, dans lequel l'algorithme Fisher-EM a été appliqué aux cinq paramètres physiques ainsi qu'aux spectres issus du survey *Sloan Digital Sky Survey* (SDSS). L'objectif était de comparer les classifications obtenues avec Fisher-EM à celles obtenues par Turner et al. avec la méthode *k-means* pour la classification avec les paramètres physiques.

Mon travail s'inscrit dans la continuité de cette étude. Il consiste à étendre l'utilisation de Fisher-EM aux données spectroscopiques obtenues avec le survey **AAOmega**. Les caractéristiques de l'instrument AAOmega ainsi que les données spectroscopiques utilisées dans cette étude sont présentées plus en détail dans la section 3.1.2. L'objectif est ainsi d'étudier la classification des galaxies à partir de leur information spectrale et de comparer les résultats avec ceux issus de la classification basée sur les 5 paramètres physiques.

3.0.1 L'échantillon de galaxies

L'échantillon initial a été extrait à partir de la base de données GAMA DR4 [3] à l'aide d'une requête SQL. Les critères de sélection appliqués sont les suivants :

- Le redshift $0.002 < z < 0.06$.
- une limite sur la magnitude apparente de Petrosian dans la bande $r < 19.8$.
- La qualité du redshift $nQ > 2$

Le redshift z mesure le décalage des raies spectrales d'une galaxie vers les grandes longueurs d'ondes et permet d'estimer sa distance. La contrainte $0.002 < z < 0.06$ permet de sélectionner des galaxies de l'univers local, tout en excluant les objets trop proches ou trop éloignés.

La magnitude de Petrosian r est une mesure de la luminosité apparente d'une galaxie, c'est-à-dire de la quantité de lumière reçue depuis la Terre dans la bande spectrale r . Plus la valeur de la magnitude est faible, plus la galaxie apparaît lumineuse. La condition $r < 19.8$ permet donc de sélectionner les galaxies suffisamment lumineuses pour être détectées dans le relevé GAMA.

La qualité du redshift nQ désigne la qualité normalisée du décalage vers le rouge. La condition $nQ > 2$ permet de sélectionner les galaxies dont la mesure du redshift est considérée comme suffisamment précise.

Ces critères ont été choisis par Turner et al. (2018)[7] afin de construire un échantillon homogène de galaxies locales, avec une limite en magnitude adaptée au relevé GAMA et des mesures de redshift de qualité suffisante. Un échantillon de 7556 galaxies est obtenu. Chaque galaxie étant associée à 5 paramètres physiques utilisés pour caractériser ses propriétés. Ces paramètres physiques sont disponibles dans la DR4 de GAMA survey sous les noms de variables et dans des les tables suivantes :

Paramètre	Variable	Table
Masse stellaire M_*	mass_stellar_best_fit	MagPhysv06
Couleur $u - r$	uminusr	StellarMassesLamdarv20
indice de sérsic	n	SersicCatSDSSv09
Rayon effectif $R_{1/2}$	GALRE_r	SersicCatSDSSv09
taux de formation d'étoiles sSFR	sSFR_0_1Gyr_best_fit	MagPhysv06

Description des paramètres :

- **Masse stellaire** M_* : masse totale des étoiles présentes dans la galaxie, exprimée en masses solaires.
- **Couleur** $u - r$: différence entre les magnitudes mesurées dans les bandes u et r . Elle renseigne notamment sur les populations stellaires et l'activité de formation stellaire.
- **Indice de Sérsic** n : paramètre décrivant la concentration de la lumière dans la galaxie. Une valeur faible correspond généralement à une distribution plus étendue, tandis qu'une valeur élevée indique une concentration plus importante vers le centre.
- **Rayon effectif** $R_{1/2}$: rayon à l'intérieur duquel se trouve environ 50 % de la lumière totale de la galaxie. Il permet de caractériser sa taille.
- **Taux de formation stellaire spécifique (sSFR)** : taux de formation d'étoiles rapporté à la masse stellaire de la galaxie. Il permet de caractériser l'activité de formation stellaire relativement à la quantité d'étoiles déjà présentes.

3.0.2 Extraction et nettoyage des données

Un échantillon initial de 7556 galaxies a été extrait via une requête SQL 3.1 depuis la base GAMA, puis téléchargé au format (.csv) et analysé dans RStudio.

```

SELECT t1.CATAID
FROM TilingCatv46 as t1
INNER JOIN VisualMorphologyv03 as t2 on t2.CATAID = t1.CATAID
WHERE t1.R_PETRO < 19.8
AND t1.SURVEY_CLASS >= 1
AND t1.Z BETWEEN 0.002 AND 0.06
AND t1.NQ > 2
AND t2.HUBBLE_TYPE NOT LIKE '-'

```

TABLE 3.1 – Requête SQL utilisée pour obtenir l'échantillon de 7556 galaxies

Une première étape de nettoyage a consisté à supprimer les valeurs manquantes (NA), réduisant l'échantillon à 7540 galaxies.

Dans un second temps, les objets contaminés (étoiles et artefacts identifiés via la variable *Hubble Type*) ont été exclus, conduisant à un sous-échantillon de 7516 galaxies.

Une étape supplémentaire a consisté à appliquer les conditions aux limites définies dans l'étude de Turner et al. [7]. Ces limites permettent d'écarter les valeurs extrêmes des paramètres physiques susceptibles d'influencer la classification et de rendre l'échantillon plus homogène. Pour les paramètres présentant des variations sur plusieurs ordres de grandeur, les bornes sont définies sur leur logarithme afin de travailler sur une échelle plus compacte.

Les conditions aux limites sont les suivantes :

Paramètre	Min	Max
$\log(M_*)$	6	12
$u - r$	0.3	2.7
$\log(n)$	-0.6	1.2
$\log(R_{1/2})$	-1.0	1.5
$\log(sSFR)$	-14	-8

TABLE 3.2 – Conditions aux limites des 5 paramètres physiques

3.0.3 Traitement des unités et standardisation

L'application initiale des contraintes a conduit à un échantillon de 7338 galaxies. Toutefois, une analyse plus fine a révélé une incohérence liée aux unités du rayon effectif, exprimé en secondes d'arc¹ dans la base de données. Or, les conditions physiques utilisées dans cette étude étant définies en kiloparsecs kpc², une conversion d'unités a été nécessaire.

Afin d'effectuer cette conversion, j'ai eu besoin du module de distance associé à chaque galaxie. Le fichier `DistancesFramesv12.fits`, contenant ces informations, n'étant plus disponible directement dans la version actuelle des données GAMA et ayant été remplacé par la version `DistancesFramesv14.fits`, le fichier `DistancesFramesv12.fits` m'a été fourni par mon encadrante. J'ai extrait les données nécessaires de ce fichier puis je les ai associées au catalogue principal à l'aide de l'identifiant unique **CATAID**.

1. La seconde d'arc (arcsec) est une unité d'angle utilisée en astronomie et correspond à 1/3600 de degré.

2. Le kiloparsec (kpc) est une unité de distance utilisée en astronomie. et correspond à environ 3262 années-lumière.

La variable `DM_70_30_70`, issue de ce fichier, correspond au module de distance³. utilisé pour la suite du calcul. La distance de luminosité D_L , exprimée en Mpc, est alors obtenue à partir du module de distance selon :

$$D_L = 10^{\frac{DM-25}{5}}.$$

En m'appuyant sur les relations décrites par Hogg [4], j'ai ensuite calculé la distance angulaire D_A ⁴ à partir de la distance de luminosité et du redshift z :

$$D_A = \frac{D_L}{(1+z)^2}.$$

J'ai ainsi converti le rayon effectif en kiloparsecs :

$$R_{1/2,\text{kpc}} = R_{1/2,\text{arcsec}} \frac{D_A \times 1000}{206265}.$$

Par ailleurs, certaines variables étant déjà normalisées dans la base de données, j'ai réalisé une homogénéisation des échelles à l'aide de la fonction `scale()` sous R. Cette standardisation permet de placer les différentes variables sur une échelle comparable avant leur utilisation dans l'analyse de clustering.

3.1 Spectres de galaxie

Après avoir constitué et homogénéisé l'échantillon à partir des cinq paramètres physiques, je me suis ensuite intéressée aux spectres associés à ces mêmes galaxies afin d'étudier leur classification à partir de leur information spectrale.

Dans cette étude, j'ai utilisé deux ensembles de spectres : les spectres (SDSS) 3.1.1 et ceux du survey AAOmega. Les premiers ont été utilisés afin de valider mon traitement des données en comparant mes résultats avec ceux obtenus dans l'étude précédente de la stagiaire. J'ai ensuite appliqué le même processus aux données AAOmega 3.1.2, qui constituent les données principales de mon étude.

3.1.1 Spectres SDSS

Les spectres du Sloan Digital Sky Survey (SDSS) ont été extraits depuis la base GAMA via une requête SQL 3.3 ci-dessous. L'échantillon initial contient 2591 spectres, dont 2554 sont associés à des galaxies appartenant à l'échantillon principal..

```
SELECT t1.CATAID, t3.FILENAME, t3.URL
FROM TilingCatv46 as t1
INNER JOIN VisualMorphologyv03 as t2 on t2.CATAID = t1.CATAID
LEFT OUTER JOIN ExternalSpecAllv07 as t3 on t3.CATAID = t1.CATAID
WHERE t1.R_PETRO < 19.8
AND t1.SURVEY_CLASS >= 1
AND t1.Z BETWEEN 0.002 AND 0.06
AND t1.NQ > 2
AND t2.HUBBLE_TYPE NOT LIKE '-'
AND t3.SURVEY='SDSS'
AND t3.IS_SBEST = 1
```

TABLE 3.3 – Requête SQL utilisée pour obtenir 2591 spectres SDSS

3. D_M est une grandeur logarithmique permettant de déterminer la distance de luminosité d'une galaxie

4. La distance angulaire permet de relier la taille apparente d'une galaxie, mesurée en secondes d'arc, à sa taille physique.

La première partie de mon travail a consisté à travailler sur une base de spectres issus du *2dF Galaxy Redshift Survey* (2dFGRS). L’objectif initial était de vérifier s’ils pouvaient être utilisés pour la classification.

Cependant, la comparaison avec les spectres SDSS a montré que les spectres issus du 2dFGRS disponibles dans la base GAMA ne sont pas correctement calibrés. Leur forme spectrale présente des différences importantes par rapport aux spectres SDSS, ce qui ne permet pas de les utiliser pour une classification quantitative. On a donc choisi de ne pas retenir ces spectres pour la suite de l’étude.

3.1.2 Survey AAOmega

Suite à ces limitations, le survey AAOmega a été retenu. Celui-ci fournit des spectres calibrés, compatibles avec une analyse quantitative.

Les données utilisées dans cette étude sont des spectres obtenus avec le spectrographe AAOmega, installé sur le télescope Anglo-Australien (AAT). Ils couvrent une plage de longueurs d’onde comprise entre 3700 et 8800 Å. La résolution spectrale de l’instrument est caractérisée par $R = \lambda/\Delta\lambda = 1300$.

Une requête SQL 3.4 a permis d’extraire 3870 spectres de galaxies, dont 3740 sont associés à l’échantillon principal de 7338 galaxies. Parmi ceux-ci, 281 galaxies sont communes avec le survey SDSS.

La distribution des cinq paramètres physiques pour les galaxies associées aux spectres AAOmega, ainsi que pour celles communes avec l’échantillon de Turner et al. (2018), est présentée en figure 3.1.

Une analyse qualitative des spectres SDSS et AAOmega montre une forte cohérence, validant l’hypothèse de calibration des flux et justifiant leur utilisation pour la classification non supervisée.

```
SELECT t1.CATAID, t3.FILENAME, t3.URL
FROM TilingCatv46 as t1
INNER JOIN VisualMorphologyv03 as t2 on t2.CATAID = t1.CATAID
LEFT OUTER JOIN AATSpecAll as t3 on t3.CATAID = t1.CATAID
WHERE t1.R_PETRO < 19.8
AND t1.SURVEY_CLASS >= 1
AND t1.Z BETWEEN 0.002 AND 0.06
AND t1.NQ > 2
AND t2.HUBBLE_TYPE NOT LIKE '-'
AND t3.IS_SBEST = 1
```

TABLE 3.4 – Requête SQL utilisée pour obtenir 3870 spectres AAOmega




FIGURE 3.1 – Distribution des galaxies de l'échantillon disposant d'un spectre AAOmega selon les 5 paramètres physiques (Masse stellaire, couleur, indice de sersic, rayon effectif et taux de formation stellaire).

3.1.3 Prétraitement des spectres

1. Calcul des longueurs d'onde observées

Les spectres AAOmega sont fournis au format FITS. Pour chaque spectre, j'ai reconstitué les longueurs d'onde observées à partir des informations contenues dans l'en-tête du fichier FITS, notamment les mots-clés `CRVAL1`, `CRPIX1` et `CD1_1`. La longueur d'onde associée au pixel i est calculée selon la relation suivante :

$$\lambda_i = \text{CRVAL1} + (i - \text{CRPIX1}) \times \text{CD1_1},$$

Tels que chaque spectre est représenté avec les métadonnées spectrales suivantes :

- `imdat` : flux.
- `crval` : longueur d'onde de référence.
- `crpix` : pixel de référence.
- `CD1_1` : pas spectral.

Après le calcul de toutes les longueurs d'ondes, j'ai pu reconstituer exactement les mêmes spectres (Voir figure 3.2).




FIGURE 3.2 – Comparaison entre le spectre reconstruit à partir des données du fichier FITS (en haut) et le spectre de référence fourni par GAMA (en bas).

2. Correction des longueurs d'ondes

Afin de comparer les spectres dans un même référentiel physique, j'ai corrigé les spectres du redshift :

$$\lambda_{\text{corr}} = \frac{\lambda_{\text{obs}}}{1 + z}$$

où λ_{obs} représente la longueur d'onde observée, z le redshift et λ_{corr} est la longueur d'onde après correction.

3. Rééchantillonnage des spectres

Après correction des longueurs d'onde, les spectres doivent être projetés sur une grille commune afin de permettre leur comparaison. La grille est définie comme suit :

- λ_{min} : maximum des longueurs d'onde minimales,
- λ_{max} : minimum des longueurs d'onde maximales,
- dt : plus petit pas spectral observé.

Remarque :

Après l'application de cette méthode de rééchantillonnage, nous avons décidé d'élargir l'intervalle de longueurs d'onde, car nous nous sommes rendu compte qu'un seul spectre imposait une longueur d'onde minimale très faible. Cela entraînait une perte importante d'informations pour les autres spectres. Nous avons donc retiré les spectres dont les longueurs d'onde étaient trop faibles, ce qui nous a conduits à une base de 3737 spectres. On obtient donc cet intervalle de rééchantillonnage :

$$\lambda_{\min} = 3718.658, \quad \lambda_{\max} = 8350, \quad dt = 0.7283717$$

Deux méthodes d'interpolation ont été testées :

- la fonction `approx()` sous R,
- la fonction `resample()` du package `signal`.

La méthode `approx()` a été retenue car elle conserve mieux les structures spectrales 3.3.




FIGURE 3.3 – Rééchantillonnage avec la fonction `approx()`

4. Normalisation

En dernière étape, j'ai normalisé les spectres afin de les rendre comparables entre eux. J'ai divisé chaque spectre par sa valeur moyenne du flux entre 5600 Å et 5800 Å. Cette normalisation permet de réduire l'influence des variations d'échelle du flux entre les différentes observations tout en conservant la forme spectrale caractéristique de chaque galaxie.

À l'issue de ces différentes étapes de prétraitement 3.4, la matrice spectrale finale obtenue est de dimension 3737×6351 , où chaque ligne correspond à un spectre de galaxie et chaque colonne à une longueur d'onde de la grille commune.

Avant l'application de l'algorithme Fisher-EM, la chaîne de prétraitement a été validée sur les spectres SDSS déjà analysé dans le travail précédent. Les résultats obtenus, notamment la structure de la matrice spectrale finale et les classifications obtenues après application de Fisher-EM, étant cohérents avec ceux de cette étude de référence, le processus de traitement a été considéré comme validé. La matrice spectrale AAOmega obtenue a ainsi pu être utilisée comme entrée pour l'étape de clustering.




FIGURE 3.4 – Chaîne de prétraitement appliquée à un spectre AAOmega : correction du redshift, ré-échantillonnage sur une grille commune et normalisation du flux.

Remarque :

La comparaison du spectre avant et après prétraitement montre que les différentes étapes appliquées ne modifient pas sa structure spectrale. Les principales caractéristiques du spectre sont conservées, notamment sa forme générale et ses raies. Cette vérification a permis de valider le traitement des spectres avant leur utilisation comme données d'entrée pour la classification par Fisher-EM.

Algorithme de Machine Learning non supervisé

Le clustering est une technique d'apprentissage automatique non supervisé dont l'objectif est de regrouper automatiquement des observations similaires, sans disposer d'étiquettes préalables. Parmi les approches les plus utilisées figurent les modèles de mélange gaussiens (Gaussian Mixture Models, GMM), qui supposent que les données sont générées par un mélange de plusieurs distributions gaussiennes. Cependant, lorsque les données sont de grande dimension, comme les spectres de galaxies contenant plusieurs milliers de longueurs d'onde, les méthodes de clustering classiques rencontrent des difficultés. En effet, la présence d'un grand nombre de variables augmente le coût de calcul, favorise la présence de variables redondantes et dégrade les performances de la classification, phénomène connu sous le nom de malédiction de la dimension (curse of dimensionality). Afin de répondre à cette problématique, C.Bouveyron et C.Brunet (2012)[2] ont proposé l'algorithme Fisher-EM, une extension de l'algorithme EM qui intègre une étape de projection discriminante inspirée du critère de Fisher. Cette approche recherche un sous-espace latent de faible dimension dans lequel les groupes sont les mieux séparés, tout en conservant les propriétés probabilistes des modèles de mélanges gaussiens. Fisher-EM est ainsi particulièrement adapté à la classification de données de grande dimension, telles que les spectres astronomiques utilisés dans cette étude.

4.1 Algorithme Fisher-EM

FisherEM repose sur la famille des Discriminative latent Mixture models (DLM) qui supposent que :

- Chaque observation est projetée dans un espace latent discriminant de dimension d avec ($d \leq K - 1$), où K désigne le nombre de classes
- Le modèle de mélange gaussien est appris dans cet espace latent.
- le bruit résiduel est modélisé dans l'espace orthogonal.

Considérons $\{y_i\}_{i=1}^n \in R^p$ les données à classer en K groupes homogènes, ajouter $z_i = \{1, \dots, K\}$ à l'observation y_i où $z_i = k$ indique que la donnée y_i appartient au cluster k . De plus on fait l'hypothèse que $\{y_i\}_{i=1}^n$ et $\{z_i\}_{i=1}^n$ sont des réalisations indépendantes respectivement d'un vecteur aléatoire $Y \in R^p$ et d'une variable aléatoire $Z \in \{1 \dots K\}$.

On définit $E \subset R^p$ un espace latent de dimension $d \leq K - 1$, correspondant au sous-espace le plus discriminant pour séparer les K groupes. On suppose que sa dimension d est strictement inférieure à la dimension p de l'espace des observations.

Dans cet espace latent, $\{x_i\}_{i=1}^n \in E$ représentent des données réelles qui sont des réalisations indépendantes d'un vecteur aléatoire $X \in E$. Le lien entre $Y \in R^p$ et celle de l'espace latent $X \in E$ est supposé être une transformation linéaire.

$$Y = UX + \varepsilon, \quad (4.1)$$

tels que : U est une matrice de taille $p \times d$ vérifiant $U^t U = \mathbf{I}_d$ et ε est un bruit gaussien :

$$\varepsilon \sim \mathcal{N}(0, \phi) \quad \text{et} \quad X|_{Z=k} \sim \mathcal{N}(\mu_k, \Sigma_k), \quad (4.2)$$

Où :

$\mu_k \in E$, $\Sigma_k \in R^{p \times p}$ sont respectivement le vecteur de moyennes et la matrice de covariance de la classe k dans l'espace latent E et $\phi \in R^{d \times d}$ la matrice de covariance associée au bruit et $\mathcal{N}(\cdot)$ représente la loi gaussienne .

D'après (4.1), ces hypothèses impliquent que la distribution de probabilité conditionnelle de Y est $Y|_{X,Z=k} \sim \mathcal{N}(UX, \phi)$, alors sa distribution marginale est donc un mélange de lois gaussiennes.

4.1.1 Modèle de mélanges gaussiens

Fisher-EM repose sur les modèles de mélanges gaussiens. Contrairement aux méthodes de partitionnement telles que k-means, les GMM adoptent une approche probabiliste en attribuant à chaque observation une probabilité d'appartenir à chacune des classes. La densité de probabilité d'une observation X s'écrit alors :

$$f(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x; m_k, S_k)$$

où :

- K représente le nombre de classes,
- π_k est la probabilité a priori (ou poids) de la classe k ,
- $m_k = U\mu_k$ est le vecteur moyen de la classe k ,
- $S_k = U\Sigma_k U^t + \phi$ est la matrice de covariance de la classe k ,
- $\mathcal{N}(\cdot)$ est la densité gaussienne multivariée.
- Les paramètres μ_k et Σ_k définissent les distributions dans l'espace latent discriminant, tandis que m_k et S_k correspondent aux paramètres induits dans l'espace initial des observations.




FIGURE 4.1 – Représentation d'un modèle de mélange gaussien composé de 3 distributions gaussiennes. Chaque composante représente une classe du mélange

Chaque observation est ainsi modélisée comme issue probabilistiquement d'une des K composantes du mélange.

On introduit

$$W = [U; V]$$

une matrice $p \times p$ qui vérifie :

$$W^t W = W W^t = I_p$$

où $V \in R^{p \times (p-d)}$ est le complément orthogonal de U défini précédemment. Enfin, on suppose que la variance du bruit ϕ vérifie :

$$V^t \phi V = \beta I_{p-d}$$

et

$$U^t \phi U = 0_d$$

telle que :

$$\Delta_k = W^t S_k W = \begin{pmatrix} \Sigma_k & 0 \\ 0 & \beta I_{p-d} \end{pmatrix}.$$

On fera référence à ce modèle comme étant le modèle **DLM** $[\Sigma_k \beta]$.

Par ailleurs, en relâchant les contraintes sur les matrices de covariance Σ_k et βI_{p-d} , il est possible de décliner 11 autres modèles [2].

En considérant l'ensemble de ces hypothèses, l'espérance de la log-vraisemblance complétée $Q(y_1, \dots, y_n; U, \theta)$ du modèle **DLM** $[\Sigma_k \beta]$ s'écrit :

$$Q(U; \theta) = -\frac{1}{2} \sum_{k=1}^K n_k \left[-2 \log(\pi_k) + \text{trace} \left(\Sigma_k^{-1} U^t C_k U \right) + \log(|\Sigma_k|) \right. \\ \left. + (p-d) \log(\beta) + \frac{1}{\beta} \left(\text{trace}(C) - \sum_{j=1}^d u_j^t C u_j \right) + \gamma \right].$$

où C_k est la matrice de covariance empirique de la classe k , u_j est le j -ème vecteur colonne de la matrice U , n_k est défini par :

$$n_k = \sum_{i=1}^n t_{ik},$$

où t_{ik} représente la probabilité a posteriori qu'une observation y_i appartienne au groupe k , et :

$$\gamma = p \log(2\pi)$$

est une constante.

L'objectif de l'algorithme Fisher-EM est d'estimer les paramètres du modèle $\theta = (\pi_k, \mu_k, \Sigma_k, U, \phi)$ en maximisant la vraisemblance complétée du modèle. Dans un contexte non supervisé, la maximisation directe de $Q(U; \theta)$ n'étant pas faisable, la méthode suit une procédure itérative en trois étapes :

- **Étape E :** Cette étape calcule , pour $k = 1, \dots, K$ et $i = 1, \dots, n$ la probabilité conditionnelle $t_{ik}^{(q)} = P(Z = k|Y = y_i)$ [1] comme suit :

$$t_{ik}^{(q)} = 1 / \sum_{l=1}^K \exp\left(\frac{1}{2}(D_k^{(q-1)}(y_i) - D_l^{(q-1)}(y_i))\right)$$

avec

$$D_k^{(q-1)}(y_i) = \|P(y_i - m_k^{(q-1)})\|_{\mathcal{D}_k}^2 + \frac{1}{\beta_k^{(q-1)}} \|(y_i - m_k^{(q-1)}) - P(y_i - m_k^{(q-1)})\|^2 \\ + \log(|\Sigma_k^{(q-1)}|) + (p - d)\log(\beta_k^{(q-1)}) - 2\log(\pi_k^{(q-1)}) + \gamma, \quad (4.3)$$

Où $\|y\|_{\mathcal{D}_k}^2 = y^t \mathcal{D}_k y$, $\mathcal{D}_k = \tilde{W} \Delta_k^{-1} \tilde{W}^t$, $\tilde{W}$ est la matrice composée des d colonnes de $U^{(q-1)}$ complétée par des zéros, $P(y) = U^{(q-1)} U^{(q-1)t} y$.

- **Étape F :** Elle détermine la transformation linéaire :

$$U \in R^{p \times d}$$

sous contrainte d'orthogonalité de ses colonnes, correspondant à la base du sous-espace latent de dimension $d \leq K - 1$ dans lequel les K groupes sont le mieux séparés.

Pour celà, le critère de Fisher classique :

$$J(U) = \text{trace} \left((U^t S U)^{-1} U^t S_B U \right)$$

est adapté au contexte non supervisé sous la contrainte :

$$U^t U = I_d.$$

Ainsi :

$$U^{(q)} = \underset{U}{\text{argmax}} \text{ trace} \left((U^t S U)^{-1} U^t S_B^{(q)} U \right)$$

sous la contrainte :

$$U^t U = I_d.$$

où S représente la matrice de covariance empirique des données et :

$$S_B^{(q)} = \frac{1}{n} \sum_{k=1}^K n_k^{(q)} (m_k^{(q)} - \bar{y})(m_k^{(q)} - \bar{y})^t$$

est la matrice de covariance inter-classe floue avec :

$$n_k^{(q)} = \sum_{i=1}^n t_{ik}^{(q)} \\ m_k^{(q)} = \frac{1}{n_k^{(q)}} \sum_{i=1}^n t_{ik}^{(q)} y_i$$

et :

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

- **Étape M** : Enfin, cette étape estime les paramètres du modèle $\text{DLM}[\Sigma_k/\beta]$ en maximisant l'espérance conditionnelle de la log-vraisemblance complétée $Q(y_1, \dots, y_n; U, \theta)$ définie précédemment et conditionnellement à $U^{(q)}$. Cette maximisation conduit aux formules de mise à jour des paramètres estimés suivantes :

$$\hat{\pi}_k^{(q)} = \frac{n_k^{(q)}}{n}, \quad \hat{\mu}_k^{(q)} = \frac{1}{n_k^{(q)}} \sum_{i=1}^n t_{ik}^{(q)} \hat{U}^{(q)t} y_i, \quad \hat{\Sigma}_k^{(q)} = \hat{U}^{(q)t} S_k \hat{U}^{(q)},$$

$$\hat{\beta}_k^{(q)} = \frac{\text{trace}(S_k) - \sum_{j=1}^d \hat{u}_j^{(q)t} S_k \hat{u}_j^{(q)}}{p-d}$$




FIGURE 4.2 – Schéma simplifié du fonctionnement de l'algorithme Fisher-EM appliqué au clustering des spectres de galaxies.

4.1.2 Implémentation de l'algorithme Fisher-EM sous R

L'algorithme Fisher-EM a été implémenté à l'aide du package **FisherEM** du logiciel **R**. Ce package fournit une implémentation des différents modèles DLM (Discriminative Latent Mixture Models) 4.1 ainsi que les fonctions permettant d'estimer automatiquement les paramètres du modèle par l'algorithme Fisher-EM.

L'utilisateur doit fournir en entrée une matrice de données

$$X \in R^{n \times p},$$

où n représente le nombre d'observations et p le nombre de variables. Dans notre étude, chaque observation correspond à un spectre de galaxie et les variables correspondent aux longueurs d'ondes.

Les principaux paramètres de la fonction sont les suivants :

- **X** : Matrice spectrale contenant les données à classer.
- **K** : nombre de groupes à identifier ;
- **method** : méthode utilisée pour déterminer l'espace discriminant et la matrice de projection (**svd**, **gs**, **reg**)
- **model** : modèle DLM 4.1 utilisé (par exemple **AkjBk**, **DkBk**, **AkBk**...)
- **init** : méthode d'initialisation des classes (**kmeans**, **random**...);
- **maxit** : nombre maximal d'itérations ;
- **eps** : seuil de convergence de l'algorithme. Les itérations sont arrêtées lorsque la variation du critère entre deux itérations successives devient inférieure à ce seuil.
- **crit** : le critère qui nous permet de choisir le meilleur modèle, c'est l'ICL par défaut.
- **nstart** : Nombre d'états à tester si l'initialisation est faite avec "random" ou "kmeans"
- **kernel** : pour détourner le $n \ll p$.

Et les sorties de l'algorithme sont :

- **K** : le nombre de cluster.
- **cls** : le vecteur contenant le nombre d'observations de chaque cluster.
- **P** : pour chaque observation, sa probabilité d'appartenir à chaque cluster.
- **U** : la matrice de projection sur le sous espace latent.
- **mean** : la moyenne de chaque classe.
- **prop** : Les valeurs des poids π_k .
- **D** : la matrice de covariance du GMM
- **critValue** : la valeur du critère ICL.
- **loglik** : la valeur de la log-vraisemblance obtenue pour le modèle.

TABLE 4.1 – Principaux modèles DLMs utilisés par FisherEM

Modèle	Description
DkBk	Chaque groupe possède sa propre matrice de covariance dans le sous-espace discriminant Σ_k ainsi que sa propre variance de bruit β_k . C'est le modèle de plus flexible et le plus riche en paramètres.
DkB	Chaque groupe possède sa propre matrice de covariance Σ_k , tandis que la variance de bruit est commune à l'ensemble des groupes β_k .
AkJBk	Les variances sont spécifiques à chaque direction discriminante j et à chaque groupe k . La variance du bruit est également spécifique à chaque groupe. Ce modèle offre une grande flexibilité dans la représentation des données.
AKBk	Chaque groupe possède une matrice de covariance diagonale propre ainsi qu'une variance de bruit propre.
ABk	La matrice de covariance est commune à tous les groupes, tandis que la variance du bruit est spécifique à chaque groupe.
DBk	La matrice de covariance est identique pour tous les groupes, mais la variance du bruit varie d'un groupe à l'autre.
DB	La matrice de covariance ainsi que la variance du bruit sont communes à tous les groupes. Il s'agit du modèle le plus contraint et du plus parcimonieux.
AB	La covariance et la variance du bruit sont communes à tous les groupes.

4.1.3 Critère de convergence et sélection du modèle

Pour sélectionner le nombre de groupes K et le modèle DLM, On a choisi le critère *Integrated Completed Likelihood* (ICL). Ce choix est adapté à notre problème de clustering, car l'ICL évalue non seulement la qualité d'ajustement du modèle aux données, mais tient également compte de la séparation entre les groupes et pénalise les modèles trop complexes. Il permet ainsi de privilégier une classification composée de groupes bien distincts tout en évitant de multiplier inutilement le nombre de classes. La configuration retenue est celle qui maximise la valeur de l'ICL.

4.1.4 Difficultés rencontrées lors de l'implémentation

L'implémentation de Fisher-EM sur les spectres AAOMega a nécessité plusieurs phases de tests. Une première difficulté était liée à la grande dimension des données, avec une configuration de type $n \ll p$, le nombre de longueurs d'onde étant supérieur au nombre de spectres. Cette situation rend l'estimation des paramètres plus délicate et augmente le temps de calcul. Différentes méthodes d'initialisation ont également été testées. L'initialisation **kmeans** a notamment rencontré des problèmes de convergence, tandis que l'initialisation **random** a donné des résultats plus satisfaisants. Enfin, les premières classifications produisaient des spectres moyens par classe peu satisfaisants. Le prétraitement des données a donc été réexaminé, ce qui a permis d'identifier et de corriger certaines erreurs. Après ces corrections, les spectres obtenus étaient plus cohérents et pouvaient être utilisés pour la classification. Ces différentes étapes ont permis de retenir une configuration adaptée aux données étudiées. Les résultats obtenus à partir de cette configuration sont présentés dans le chapitre suivant.

Résultats du clustering

5.1 Les spectres AAOmega




FIGURE 5.1 – Résultats de FisherEM sur AAOmega pour 29 Clusters, la courbe noire représente le spectre moyen de chaque classe et la zone grise représente 10% et 90% des quantiles

La figure 5.1 présente le résultat obtenu pour la classification des spectres AAOmega à l'aide de la méthode Fisher-EM. Pour chaque classe identifiée, sont représentés le nombre de spectres qui la composent N , le spectre moyen de la classe ainsi que la dispersion des spectres autour de ce spectre moyen. Cette représentation permet ainsi d'observer les caractéristiques spectrales propres à chaque groupe et d'évaluer la variabilité des spectres au sein des différentes classes.

Les paramètres utilisés dans la fonction `FisherEM` pour obtenir ce résultat sont les suivants :

```
Library(FisherEM)
fem(Matrice-Spectrale, K=2:32, model="all", method="svd", kernel="linear",
    init="random", maxit=60, nstart=25, nretry=5)
```

Les paramètres utilisés dans la fonction `FisherEM` pour obtenir ce résultat ont été choisis en fonction des caractéristiques des données et des tests réalisés lors de l'implémentation. La configuration retenue est la suivante :

- $K = 2, \dots, 32$: plusieurs nombres de classes ont été testés afin d'étudier l'évolution de la classification et de déterminer le nombre de groupes le plus adapté aux données ;
- `model = "all"` : l'ensemble des modèles DLM disponibles a été testé afin de sélectionner, pour chaque valeur de K , le modèle offrant le meilleur compromis entre ajustement et complexité ;
- `method = "svd"` : cette méthode a été retenue pour déterminer l'espace discriminant, notamment en raison de sa meilleure adaptation aux données de grande dimension ;
- `init = "random"` : cette initialisation a été retenue après avoir constaté des problèmes de convergence avec l'initialisation `kmeans` ;
- `nstart = 25` : 25 initialisations aléatoires ont été réalisées afin de limiter l'influence du choix initial des groupes ;
- `maxit = 60` : ce nombre maximal d'itérations permet de laisser suffisamment d'itérations à l'algorithme pour atteindre la convergence ;

Remarque :

Compte tenu de la dimension importante des données spectroscopiques et du nombre de classifications à effectuer pour différentes valeurs de K et différents modèles DLM, les temps de calcul de Fisher-EM peuvent devenir importants. Les calculs n'ont donc pas été réalisés directement sur mon ordinateur personnel, mais sur une machine de calcul mise à disposition par l'IRAP.

Cette machine est accessible à distance depuis mon ordinateur. Pour établir la connexion, j'ai utilisé un tunnel SSH (*Secure Shell*), permettant d'accéder à l'environnement de calcul distant de manière sécurisée. J'ai ainsi pu lancer les scripts R et effectuer les différentes classifications directement sur le serveur, tout en récupérant les résultats sur mon ordinateur.

L'utilisation de cette machine a notamment permis de réaliser plusieurs lancements de Fisher-EM avec différentes configurations, en particulier pour tester plusieurs valeurs de K , différents modèles DLM et plusieurs initialisations. Cette organisation a été nécessaire pour mener les calculs dans des conditions adaptées à la taille des données et au nombre de tests réalisés.

Les valeurs de l'ICL obtenues pour les différentes valeurs de K sont présentées dans le tableau 5.1.

K	ICL	Modèle sélectionné
2	-25586959	AjBk
$\vdots$	$\vdots$	$\vdots$
25	-11918416	AkBk
26	-11979172	AkBk
27	-11872993	AkBk
28	-11850824	AkjBk
29	-11807976	AkBk
30	-11864927	AkjBk
31	-11896320	AkBk
32	-11989746	DBk

TABLE 5.1 – Valeurs de l'ICL et modèles Fisher-EM sélectionnés pour différentes valeurs de K .

On observe une augmentation de la valeur de l'ICL avec le nombre de classes jusqu'à ($K=29$), pour lequel l'ICL atteint sa valeur maximale. À partir de ($K=30$), une diminution de l'ICL est observée. Ainsi, le modèle comportant (29) classes constitue la meilleure configuration parmi les modèles testés.

On remarque également que le modèle (AkBk) est sélectionné pour une grande partie des valeurs de (K) testées. Ce modèle est caractérisé par une matrice de covariance diagonale propre à chaque groupe ainsi qu'une variance de bruit propre à chaque classe. Sa sélection fréquente suggère donc que les différentes classes de spectres présentent des niveaux de dispersion et de bruit qui peuvent être différenciés d'une classe à l'autre. Le critère ICL favorise ainsi, pour plusieurs valeurs de (K), un modèle permettant de prendre en compte cette variabilité spécifique aux différentes classes.

Cette première classification a été réalisée sur la grille de longueurs d'onde propre aux spectres AAOmega. Afin de poursuivre l'étude et de permettre une comparaison avec les spectres SDSS, j'ai réalisé deux étapes supplémentaires. La première consiste à appliquer Fisher-EM aux spectres AAOmega après leur rééchantillonnage sur la grille utilisée pour les spectres SDSS. Cette classification est présentée dans la section 5.2. La seconde consiste à réaliser une classification conjointe des spectres AAOmega et SDSS sur cette même grille, présentée dans la section 5.3.

5.2 Les spectres AAOmega sur une grille de rééchantillonnage des spectres SDSS

Pour préparer la classification conjointe des spectres AAOmega et SDSS, j'ai d'abord réalisé une classification des spectres AAOmega après leur rééchantillonnage sur la grille de longueurs d'onde utilisée pour les spectres SDSS. La grille utilisée est définie comme suit :

Longueur d'onde minimale	4573.492 Å
Longueur d'onde maximale	7280.389 Å
Le pas	0.7353881




FIGURE 5.2 – Résultat de la classification pour $K = 20$ avec une valeur maximale de $l'ICL = -1149586$ et le modèle choisit est $AkjBk$

5.3 Les spectres AAOmega avec les spectres SDSS

Après avoir rééchantillonné les spectres AAOmega sur la même grille de longueurs d'onde que les spectres SDSS, j'ai réalisé une classification conjointe des deux ensembles de spectres à l'aide de Fisher-EM. Cette classification permet de regrouper les spectres AAOmega et SDSS dans un même espace et constitue une étape supplémentaire pour comparer les informations spectrales avec les regroupements obtenus à partir des cinq paramètres physiques.




FIGURE 5.3 – Résultat de la classification des spectres SDSS avec ceux de AAOmega pour $K = 6$ classes et une valeur maximum de $l'ICL = 2301054$, modèle choisi est $AkjBk$

Conclusion et perspectives

Ce stage réalisé au sein de l’Institut de **R**echerche en **A**strophysique et **P**lanétologie (IRAP) a permis d’étudier l’utilisation des méthodes de Machine Learning pour la classification non supervisée des galaxies à partir de leurs spectres.

Dans un premier temps, un travail de préparation et de traitement des données a été réalisé à partir des données du relevé GAMA et des spectres obtenus avec l’instrument AAOmega. Cette étape a notamment consisté à sélectionner les galaxies, traiter les spectres, corriger l’effet du redshift, rééchantillonner les données sur une grille commune et normaliser les flux. Ces différentes étapes ont permis d’obtenir une matrice spectrale homogène pouvant être utilisée pour les méthodes de clustering.

Dans un second temps, nous avons étudié l’algorithme Fisher-EM, fondé sur les modèles de mélanges latents discriminants (DLM). Cette méthode permet de rechercher un espace latent de dimension réduite dans lequel les différentes classes sont au mieux séparées. L’algorithme alterne ainsi les étapes E, Fisher et M afin d’estimer simultanément les probabilités d’appartenance aux classes, l’espace discriminant et les paramètres du modèle.

Les premières classifications réalisées sur les spectres AAOmega ont permis d’explorer différents nombres de classes et différents modèles DLM. Le critère ICL a été utilisé afin de comparer les modèles et de sélectionner la configuration la plus pertinente. Les résultats obtenus montrent notamment une préférence pour certains modèles, en particulier le modèle **AkBk** dans les classifications étudiées.

Ce travail a également mis en évidence les difficultés liées au clustering de données spectrales de grande dimension. Le nombre de longueurs d’onde étant important par rapport au nombre de spectres, le traitement des données et l’estimation des paramètres peuvent être coûteux en temps de calcul.

6.1 Perspectives

Plusieurs pistes peuvent être envisagées pour poursuivre ce travail. Une première perspective consiste à approfondir l’analyse des classes obtenues avec Fisher-EM en étudiant leurs propriétés spectrales et leurs caractéristiques astrophysiques. Il serait notamment intéressant de comparer les spectres moyens des différentes classes et d’identifier les raies d’émission ou d’absorption caractéristiques de chacune d’entre elles.

Une autre perspective sur laquelle on est pas arrivée a trouvé de solution est de faire la classifications en utilisant les spectres de galaxies et ses paramètres physiques tels que l’algorithme prend ses deux entrées au même poids.

Bibliographie

- [1] Charles Bouveyron. Contributions à l'apprentissage statistique en grande dimension, adaptatif et sur données atypiques. <https://theses.hal.science/tel-00761130v1>, 2012. Habilitation à Diriger des Recherches.
- [2] Charles Bouveyron and Camille Brunet. Simultaneous model-based clustering and visualization in the fisher discriminative subspace. Computational Statistics and Data Analysis, 56 :301–324, 2012.
- [3] GAMA Survey. Galaxy and mass assembly (gama) survey. <https://www.gama-survey.org/>, 2025.
- [4] David W. Hogg. Distance measures in cosmology. arXiv e-prints, 1999.
- [5] IRAP. Institut de recherche en astrophysique et planétologie. <https://www.irap.omp.eu/>.
- [6] Observatoire Midi-Pyrénées. Les quatre saisons de l'omp. <https://www.news.obs-mip.fr/les-4-saisons-de-lomp-edition-2025/>, 2025. Cycle de rencontres scientifiques organisé par l'Observatoire Midi-Pyrénées.
- [7] Sebastian Turner, Lee S. Kelvin, Ivan K. Baldry, Paulo J. Lisboa, Steven N. Longmore, Chris A. Collins, Benne W. Holwerda, Andrew M. Hopkins, and Jochen Liske. Reproducible k-means clustering in galaxy feature data from the gama survey. Monthly Notices of the Royal Astronomical Society, 482(1) :126–150, 2018.

Résultats du clustering pour certains K

A.1 Les spectres AAOmega




FIGURE A.1




FIGURE A.2

La figure A.1 représente les résultats de la classification des spectres AAOmega sur sa grille de rééchantillonnage pour $K = 2$ et le modèle sélectionné est $AjBk$ avec $ICL = -25586959$, tant dis que la figure A.2 est le résultat pour $K = 18$, le modèle choisi est $AkBk$ avec une $ICL = -12335359$

A.2 Les spectres AAOmega rééchantillonnés sur la grille SDSS




FIGURE A.3

La classification obtenue avec $K = 2$ classes est présentée dans la figure A.3. Le modèle sélectionné est $AkBk$, avec une valeur de l'ICL de -8964622




FIGURE A.4

La classification obtenue avec $K = 18$ classes est présentée dans la figure A.4. Le modèle sélectionné est Ak_jBk , avec une valeur de l'ICL de -1260981




FIGURE A.5

La classification obtenue avec $K = 19$ classes est présentée dans la figure A.4. Le modèle sélectionné est $AkjBk$, avec une valeur de l'ICL de -1217085

A.3 Les spectres AAOmega et SDSS




FIGURE A.6

Le résultat du clustering des spectres AAOmega et SDSS pour $K = 2$, le modèle choisit est $AkjBk$ pour une valeur d'ICL de -8952094 .